Nama: Muhammad Tiflanil Azhar Rudin

BAGIAN A — ANALISIS KONSEPTUAL

1. Efek Regularisasi pada Batch Normalization

Rujukan materi: slide 6–8.
Batch Normalization (BN) menormalkan aktivasi menggunakan rata-rata dan varians mini-batch, kemudian menerapkan parameter skala (γ) dan pergeseran (β). Karena komposisi mini-batch berubah pada setiap iterasi, estimasi statistiknya ikut berfluktuasi. Akibatnya, aktivasi suatu sampel sedikit dipengaruhi sampel lain, menghasilkan gangguan stokastik yang dapat mengurangi ketergantungan model pada pola spesifik data latih. Inilah dasar efek regularisasi ringan yang disebut pada slide 8 [1]. Namun, BN tidak selalu menggantikan Dropout. Pada dataset sangat kecil atau model berkapasitas besar, overfitting masih dapat terjadi sehingga Dropout atau regularisasi lain tetap diperlukan. Mini-batch yang sangat kecil atau tidak representatif juga menghasilkan statistik tidak stabil, terutama saat fine-tuning atau distribusi data berubah. Karena itu, evaluasi kebutuhan Dropout harus berbasis kesenjangan performa train–validation, bukan asumsi bahwa BN otomatis cukup.

2. Degradasi Jaringan Dalam dan Formulasi Residual

Rujukan materi: slide 10–12; keterkaitan dengan vanishing gradient Sesi 02.
Secara teoritis, plain CNN yang lebih dalam dapat menyamai jaringan dangkal jika lapisan tambahannya mempelajari fungsi identitas. Akan tetapi, optimisasi fungsi identitas melalui banyak transformasi nonlinier tidak mudah; kedalaman tambahan dapat meningkatkan galat pelatihan (degradation problem), bukan sekadar overfitting [2]. Pada propagasi balik jaringan biasa, gradien melewati perkalian berulang turunan antarlapisan sehingga berisiko mengecil atau membesar, sesuai fenomena vanishing/exploding gradient pada Sesi 02. Residual block mengubah target pembelajaran menjadi $y = F(x) + x$, yakni hanya mempelajari koreksi terhadap input. Turunannya adalah $\partial L/\partial x = (\partial L/\partial y)(I + \partial F/\partial x)$, sehingga tersedia jalur gradien langsung melalui komponen identitas. Jalur ini mempermudah pelatihan jaringan dalam dan mitigasi vanishing gradient, walaupun tidak menjamin seluruh persoalan optimisasi hilang. ResNet menerapkan mekanisme tersebut secara sistematis [2].

3. Feature Extraction vs. Fine-Tuning

Rujukan materi: slide 14–16.
Feature Extraction membekukan seluruh backbone pretrained dan hanya memperbarui classifier head; jumlah parameter trainable sedikit. Pendekatan ini cocok untuk dataset kecil, relatif hemat komputasi dan memori karena tidak perlu menyimpan aktivasi backbone untuk backpropagation, serta meminimalkan risiko perubahan destruktif terhadap fitur awal. Fine-Tuning membuka sebagian atau seluruh lapisan backbone sehingga parameter yang diperbarui lebih banyak, kebutuhan data cenderung meningkat, dan biaya komputasi maupun memori per epoch lebih tinggi. Keuntungannya, representasi dapat disesuaikan dengan domain target; risikonya ialah destructive gradient updates jika learning rate terlalu besar [3]. Secara praktis, pilih Feature Extraction ketika data terbatas, kelas target mirip domain pretrained, atau sumber daya ketat. Pilih Fine-Tuning bertahap jika validasi

menunjukkan fitur beku belum memadai dan tersedia data serta anggaran komputasi yang cukup. Gunakan learning rate kecil dan kontrol performa validasi.

4. Kaidah Penerapan Data Augmentation

Rujukan materi: slide 20–22. Catatan: slide 23 pada PDF adalah pembuka 'Modern Architectures', bukan pembahasan augmentasi.
Augmentasi stokastik diterapkan hanya pada train set untuk menambah keragaman tampilan dan mendorong generalisasi tanpa mengubah label sebenarnya (slide 20–22). Validation dan test set harus menggunakan preprocessing deterministik yang konsisten, seperti resize dan normalisasi, agar evaluasi mengukur performa pada distribusi pengujian yang tetap. Jika augmentasi acak digunakan saat validasi, skor dapat berfluktuasi akibat transformasi, menyulitkan pemilihan checkpoint dan perbandingan eksperimen. Pada test set, perubahan acak juga dapat membuat hasil kurang reprodusibel; pendekatan test-time augmentation adalah prosedur evaluasi tersendiri yang harus dinyatakan eksplisit [4]. Untuk klasifikasi ras hewan peliharaan, random crop yang terlalu agresif tidak layak apabila memotong telinga, moncong, atau pola bulu—ciri penting pembeda ras. Transformasi demikian tidak menjaga invariansi semantik label: citra hasil mungkin tidak lagi mengandung bukti yang cukup untuk mendukung label asal.

5. Mitigasi Catastrophic Forgetting

Rujukan materi: slide 28–29.
Catastrophic forgetting dalam fine-tuning terjadi ketika pembaruan bobot untuk tugas baru menggeser representasi yang dipelajari dari data pretraining. Jika semua lapisan langsung dibuka dengan learning rate besar pada dataset kecil, gradien target yang sempit dapat menimpa fitur umum; performa transfer maupun generalisasi kemudian menurun (slide 28) [5]. Strategi pertama adalah differential learning rate: gunakan laju belajar sangat kecil pada lapisan awal dan lebih besar pada classifier, karena fitur rendah seperti tepi dan tekstur relatif umum, sedangkan lapisan akhir lebih spesifik tugas. Pembaruan kecil mengurangi pergeseran fitur pretrained. Strategi kedua adalah gradual unfreezing: latih classifier terlebih dahulu, lalu buka blok paling akhir dan secara bertahap blok sebelumnya. Ini membatasi perubahan simultan yang besar dan membuat adaptasi lebih terkendali [6]. Kombinasikan dengan scheduler serta checkpoint berdasarkan validasi, sebagaimana praktik pada slide 29.

DAFTAR PUSTAKA

[1] Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. ICML. https://proceedings.mlr.press/v37/ioffe15.html

[2] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR. https://doi.org/10.1109/CVPR.2016.90

[3] Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How Transferable Are Features in Deep Neural Networks? NeurIPS. https://arxiv.org/abs/1411.1792

[4] Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data, 6, 60. https://doi.org/10.1186/s40537-019-0197-0

[5] Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. PNAS, 114(13), 3521–3526. https://doi.org/10.1073/pnas.1611835114

[6] Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. ACL. https://doi.org/10.18653/v1/P18-1031 (rujukan strategi differential learning rate dan gradual unfreezing; asalnya dari NLP).

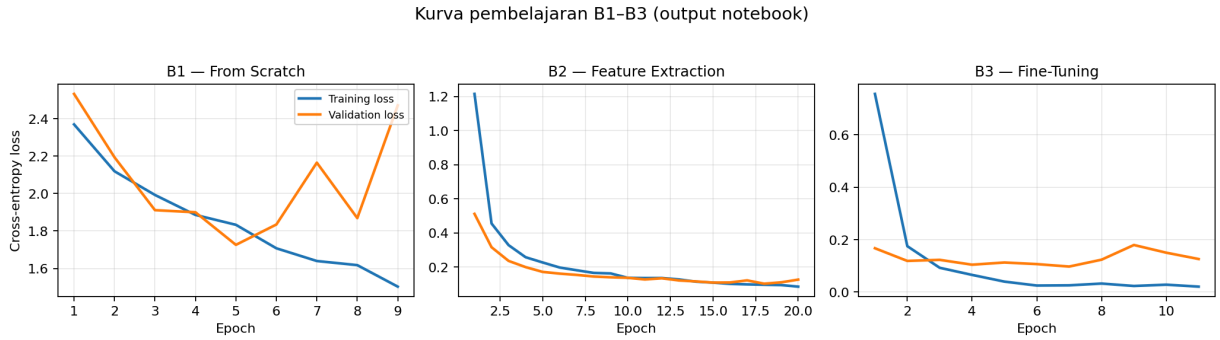
BAGIAN B — ANALISIS KONSEPTUAL

Dataset: OxfordIIIT PET
Google Co-Lab:
https://colab.research.google.com/drive/1QyC4XD0Ji1jaT_kS2vp1GUIP1GIgN3BQ#scrollTo=qEgkgzNVL9_4
Github: https://github.com/theaxisofresistance/oxfordiiit-pet-analyze

BAGIAN C — ANALISIS KONSEPTUAL

C1. TABEL KONSOLIDASI DAN VISUALISASI PEMBELAJARAN

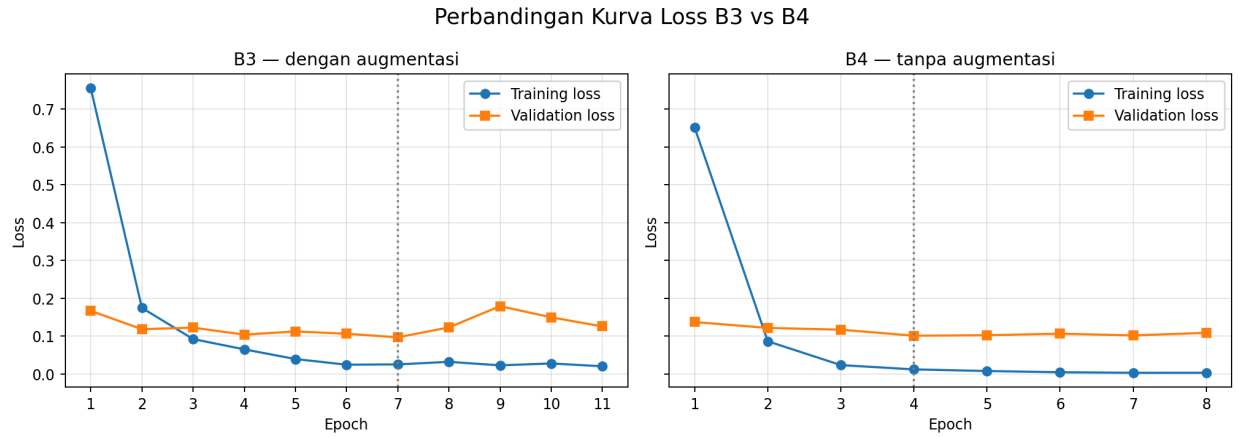
Penelitian menggunakan Oxford-IIIT Pet dengan 10 ras terpilih (1.996 citra): 1.397 train, 299 validation, dan 300 test. Seluruh eksperimen menggunakan batch size 32, AdamW, CrossEntropyLoss, serta early stopping berdasarkan validation loss dengan patience 4. B1–B4 menggunakan ResNet18; B5 menggunakan EfficientNet-B0. “Epoch konvergen” mengacu pada epoch dengan validation loss minimum, bukan selalu epoch terakhir.
B5 menghasilkan Macro F1 test tertinggi (0,9732), lebih tinggi 0,0199 daripada B4. Namun B5 dan B4 menggunakan arsitektur serta jumlah parameter yang berbeda; hasil ini bukan bukti bahwa seluruh konfigurasi EfficientNet-B0 selalu lebih baik. Durasi total juga dipengaruhi early stopping sehingga tidak boleh diperlakukan sebagai biaya komputasi per epoch.



Gambar C1. Kurva training loss dan validation loss B1–B3 berdasarkan keluaran per epoch notebook.

Grafik tambahan C1 — Perbandingan B3 (dengan augmentasi) vs B4 (tanpa augmentasi) dan B3 vs B5 (efficient net)

B3 mencapai validation loss terbaik 0,0971 (epoch 7), sedangkan B4 mencapai 0,1013 (epoch 4). Generalization gap pada best epoch tercatat 2,51 pp (B3) dan 3,68 pp (B4); namun metrik training B3 memakai gambar teraugmentasi sehingga gap tidak sepenuhnya setara. Macro F1 test B4 (0,9533) sedikit lebih tinggi daripada B3 (0,9503), sehingga efek augmentasi terhadap performa test belum konklusif.



Grafik tambahan C1 — Perbandingan B3 (ResNet18) vs B5 (EfficientNet-B0)

B5 memperoleh validation loss minimum 0,0539 pada epoch 13, lebih rendah daripada B3 (0,0971 pada epoch 7). Macro F1 test B5 juga lebih tinggi (0,9732 vs 0,9503). B3 menggunakan augmentasi sedangkan B5 tidak, sehingga perbedaan ini tidak semata-mata dapat diatribusikan pada arsitektur model.



C2. PEMBAHASAN ANALISIS KOMPARATIF

1. Disparitas from scratch dan transfer learning, B1 menginisialisasi seluruh ResNet18 secara acak dan mengoptimalkan 11.181.642 parameter hanya dari 1.397 citra train. Performanya terbatas (validation accuracy 38,13%; Macro F1 test 0,3206), sedangkan B2 dan B3 memanfaatkan representasi visual yang telah dipelajari dari ImageNet dan mencapai validation accuracy 96,99%. Transfer learning memungkinkan classifier membedakan ras dengan fitur tepi, tekstur, dan struktur objek yang sebelumnya telah terbentuk. Residual connections pada ResNet (Slide 10–12) membantu aliran gradien dan optimisasi jaringan dalam, tetapi tidak menggantikan kebutuhan data dan iterasi yang memadai untuk melatih fitur dari nol. Dengan demikian, kesenjangan hasil terutama mencerminkan manfaat pretrained representations pada small-data regime dan anggaran pelatihan yang terbatas, bukan bukti bahwa arsitektur B1 tidak mampu mencapai hasil lebih tinggi bila dilatih dengan data lebih besar.

2. Trade-off feature extraction versus progressive fine-tuning. B2 memperbarui hanya 5.130 parameter pada FC sehingga representasi backbone tetap terlindungi dari destructive gradient updates. B3 mengaktifkan layer4 dan FC (8.398.858 parameter trainable), memakai differential learning rate 1e-4/1e-3, dan menghasilkan Macro F1 test 0,9503 dibanding 0,9438 pada B2 (kenaikan 0,0065). Best validation loss B3 mencapai 0,0971 pada epoch 7, sedangkan B2 0,1017 pada epoch 18. Akan tetapi, validation loss B3 kemudian berfluktuasi, mengindikasikan risiko overfitting ketika kapasitas adaptasi diperbesar. Durasi 184,14 detik (B3) versus 327,88 detik (B2) tidak serta-merta menunjukkan biaya per epoch lebih rendah, sebab B3 berhenti setelah 11 epoch sementara B2 menyelesaikan 20 epoch. Pada data terbatas, B2 layak menjadi baseline produksi yang sederhana; B3 relevan bila kenaikan Macro F1 kecil tersebut bernilai bagi aplikasi dan tersedia memori serta komputasi tambahan.

3. Peran data augmentation. B3 memakai random crop, horizontal flip, rotasi hingga 15 derajat, serta color jitter; B4 memakai data train tanpa augmentasi. Pada best epoch, selisih train accuracy − validation accuracy yang tercatat adalah sekitar 2,51 poin persentase untuk B3 (99,50% − 96,99%) dan 3,68 poin persentase untuk B4 (100,00% − 96,32%). Selisih yang lebih kecil pada B3 konsisten dengan efek regularisasi augmentasi. Namun train accuracy B3 diukur pada citra yang diaugmentasi secara acak sehingga tingkat kesulitannya tidak identik dengan B4. Perbandingan gap yang lebih ketat memerlukan evaluasi kedua model pada train set deterministik yang sama. Selain itu, B4 justru menghasilkan Macro F1 test 0,9533, sedikit lebih tinggi daripada B3 (0,9503). Karena selisih hanya 0,0030 pada satu seed, efektivitas augmentasi terhadap test performance belum dapat dinyatakan konklusif.

C3. FAILURE ANALYSIS — MODEL TERBAIK B5

Berdasarkan Macro F1 test, model dengan hasil terbaik adalah EfficientNet-B0 fine-tuning (B5; 0,9732). Delapan sampel di bawah merupakan gambar salah klasifikasi yang tampil dalam output notebook B5. Confidence adalah probabilitas softmax kelas prediksi, bukan jaminan probabilitas benar yang telah terkalibrasi.



Gambar C3. Delapan misklasifikasi test set model B5; setiap panel berisi ground truth, prediksi, dan confidence.

Hipotesis penyebab per sampel (interpretasi visual yang perlu diverifikasi terhadap citra asli):
1. Bengal → Abyssinian (84,64%): close-up wajah dan pola bulu yang tidak sepenuhnya terlihat dapat membuat ciri dua ras tampak serupa.
2. Bengal → Maine Coon (82,35%): sudut pengambilan dari bawah, dominasi telinga, dan latar biru polos dapat mengurangi keterlihatan motif tubuh Bengal.
3. Persian → Maine Coon (62,05%): bulu panjang dan wajah yang dipotret dari atas/samping dapat menyerupai Maine Coon; karakteristik profil wajah tidak tampak jelas.
4. Bengal → Abyssinian (51,88%): foto profil samping dengan kepala mendongak menutupi sebagian ciri wajah dan pola bulu khas Bengal.

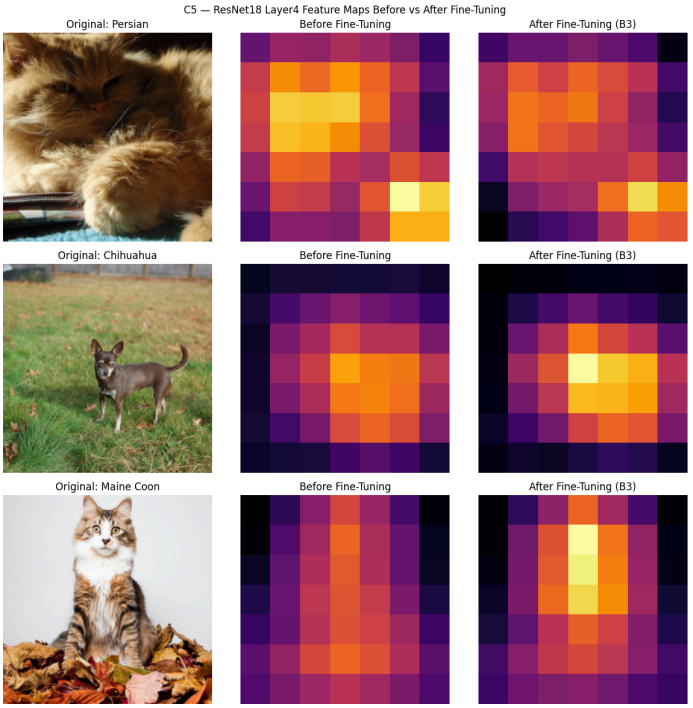
5. Pug → Boxer (99,72%): kemiripan warna bulu cokelat dan moncong gelap, serta proporsi tubuh akibat perspektif, berpotensi menyebabkan prediksi keliru dengan confidence sangat tinggi.
6. Bengal → Maine Coon (91,34%): kemiripan tekstur/tabby dan konteks outdoor dapat membuat model lebih mengandalkan tampilan umum daripada motif ras.
7. Bengal → Maine Coon (57,08%): ekspresi mulut terbuka, pose tidak lazim, dan crop wajah ekstrem dapat mengganggu fitur pembeda ras.
8. Siamese → Abyssinian (42,06%): wajah hanya terlihat sebagian pada tepi kanan citra dan latar mesin jahit cukup dominan; oklusi/crop serta background bias diduga berkontribusi.
Kesalahan tidak membuktikan penyebab kausal tertentu; hipotesis tersebut perlu diperiksa dengan inspeksi citra, confidence antarkelas, dan bila memungkinkan Grad-CAM. Kasus Pug → Boxer pada confidence 99,72% secara khusus menunjukkan bahwa model dapat sangat yakin sekalipun salah.

C4. REKOMENDASI REKAYASA DAN BATASAN EKSPERIMEN

Rekomendasi. Untuk tugas klasifikasi 10 ras dengan data berlabel terbatas, pilih EfficientNet-B0 fine-tuning (B5) sebagai kandidat utama berdasarkan Macro F1 test tertinggi 0,9732 dan hanya 424.970 trainable parameters. Verifikasi performa pada data eksternal dan lakukan pengujian waktu inferensi, penggunaan RAM/VRAM, serta latensi perangkat target sebelum penerapan. Jika interoperabilitas ResNet18 atau kesederhanaan adaptasi menjadi prioritas, B2 merupakan baseline yang kuat: Macro F1 0,9438 dengan hanya 5.130 parameter trainable. B3 memberikan tambahan akurasi kecil dengan kapasitas optimisasi lebih besar; B4 merupakan alternatif tanpa augmentasi yang pada pengujian tunggal memberi Macro F1 0,9533. Gunakan threshold confidence/peninjauan manual pada prediksi berisiko karena output softmax belum diuji kalibrasinya.

C5. Eksplorasi Tambahan (Nilai Tambah / Opsional)

Eksplorasi ini dirancang untuk membandingkan aktivasi fitur pada blok layer4 dari ResNet18 sebelum dan sesudah progressive fine-tuning B3, menggunakan citra test yang sama. Kondisi sebelum adaptasi adalah ResNet18 pretrained ImageNet (IMAGENET1K_V1), sedangkan kondisi setelah adaptasi adalah ResNet18 B3 dengan layer4 dan classifier yang dilatih pada sepuluh kelas Oxford-IIIT Pet. Perbandingan menggunakan model pada mode eval() dan preprocessing deterministik yang sama. Aktivasi layer4 berdimensi spasial kecil; rata-rata kanal dapat divisualisasikan sebagai heatmap, dengan skala warna yang konsisten agar kedua kondisi lebih mudah dibandingkan.



C5.3. Analisis Visualisasi Feature Map

Pada sampel Persian, aktivasi sebelum fine-tuning menyebar di bagian tengah-kiri dan kanan bawah, sedangkan setelah fine-tuning intensitas di bagian tengah-kiri tampak menurun dan respons relatif menonjol di kanan bawah. Pada Chihuahua, respons kuat tetap berada di area tengah tubuh anjing, tetapi setelah fine-tuning puncak intensitas tampak lebih terlokalisasi. Pada Maine Coon, respons setelah fine-tuning tampak menguat di area tengah-atas yang secara spasial mendekati wajah dan dada kucing. Perubahan ini menunjukkan pergeseran representasi tingkat tinggi setelah adaptasi B3. Namun, feature map merupakan rata-rata aktivasi 512 kanal pada resolusi spasial 7×7, bukan penjelasan kausal keputusan model; Grad-CAM diperlukan untuk menguji kontribusi area citra terhadap prediksi kelas tertentu.
Eksperimen B2 sudah memenuhi langkah awal feature extraction. Pada B3, fine-tuning dilakukan secara parsial dengan differential learning rate dan checkpoint berdasarkan validation loss, sejalan dengan mitigasi destructive gradient updates (Slide 28–29). Eksperimen tambahan B6 telah menguji ReduceLROnPlateau, tetapi pengaruh aktual perubahan learning rate terhadap representasi layer4 belum diuji secara terpisah. Penggunaan learning-rate scheduler tidak menggantikan keharusan membandingkan aktivasi layer4 sebelum/sesudah B3.